



Analítica Computacional Para la Toma de Decisiones

Proyecto 2

Analítica de Datos Saber 11 Córdoba


Abraham Bohórquez
Samuel Arbeláez
Lucas Muñoz

Usuario Principal

Ministro de Educación de Córdoba
Martin Llaryora



Consideraciones del proyecto anterior



- Se utiliza la misma base de datos de cordoba que el proyecto anterior
- Se realiza la misma limpieza general corrigiendo errores en formato.
- Se considera el analisis de datos del proyecto anterior para ayudar a realizar los modelos y escoger variables.


Predicción de Bajo Desempeño en Inglés A-1

Matriz de confusión — modelo final (test)

Realidad	Predicción del modelo	
	No A-	A-
No A-	3,544 (12.2%)	7,816 (26.8%)
A-	920 (3.2%)	16,831 (57.8%)

- 194,000 estudiantes analizados
- 137 variables del contexto familiar y del colegio
- División estratificada train / val / test (70/15/15)
- Baseline: regresión logística → F1 = 0.72
- 5 arquitecturas de red neuronal probadas en MLflow
- Target encoding del colegio + threshold optimizado a 0.29


Predicción de Bajo Desempeño en Inglés A-1



- **El colegio pesa 5x más que cualquier otra variable**
- El colegio explica más que el estrato y la educación de los padres juntos
- Tener internet y computador en casa pesa más que el estrato directo
- Montería tiene un perfil distinto al resto de los municipios

Predicción Puntaje Global Saber Pro

Comparación Modelos



Mejor Combinación: NN + Lasso

$R^2 = 0.320$ RMSE = 38.07 MAE = 30.43

Reducción Dimensionalidad:
103 a 89 variables

La selección de variables permitió mejorar ligeramente el desempeño de la red neuronal, reduciendo complejidad sin pérdida significativa de información.

Evaluación Final

“¿Por qué el modelo es bueno?”

- **Error porcentual relativamente bajo** para datos educativos reales.
- Resultados consistentes entre validación y test.
- No hay evidencia fuerte de overfitting.

Aunque el modelo no explica toda la variabilidad del desempeño académico, logra capturar patrones relevantes utilizando únicamente variables socioeconómicas, familiares y escolares.

NN · TODAS LAS VARIABLES

13.50

MAPE %


NN + LASSO

12.94

MAPE %

Predicción de desempeño en matematicas

- Relevancia en programas universitarios, predecir si un estudiante cumple con un nivel satisfactorio en la sección de matematicas (puntaje mayor a 70)
- Obtener descriptores de estudiantes con respecto a variables con respecto al examen, el colegio, socioeconomicas y familiares.
- Se analizaron 29714 de los cuales solo el 3.95% cumple con un nivel satisfactorio de matematicas. Problema extremadamente desbalanceado
- Generar modelos de redes neuronales y XGBoost utilizando un train/test split de 80-20 y k-fold con $k = 5$ para validar
- Se prioriza el recall como metrica para reducir falsos negativos




Predicción de desempeño en matematicas: NN

	Predicho: No cumple	Predicho: Cumple
Real: No cumple	4,498 75.7% <i>Verdaderos Negativos</i>	1,210 20.4% <i>Falsos Positivos</i>
Real: Cumple	55 0.9% <i>Falsos Negativos</i>	180 3.0% <i>Verdaderos Positivos</i>

- Se entrena un modelo de redes neuronales.

- Tras validar los modelos se encontro la mejor arquitectura:
 - a. Capas densas con 256, 256, 128, 128, 64, 32 neuronas y activación ReLU
 - b. Learning rate de 0.0001
 - c. Batch size de 32



- Metricas de desempeño del modelo:

- a. Recall: 76.6%
- b. F1-score: 0.222
- c. ROC-AUC: 0.874
- d. Presición: 78.7%

Predicción de desempeño en matematicas: XGBoost

	Predicho: No cumple	Predicho: Cumple
Real: No cumple	4,441 74.7% <i>Verdaderos Negativos</i>	1,267 21.3% <i>Falsos Positivos</i>
Real: Cumple	41 0.7% <i>Falsos Negativos</i>	194 3.3% <i>Verdaderos Positivos</i>


- Se entrena un modelo de arboles de decisión usando XGBoost.

- Tras validar los modelos se encontro el mejor:

- Numero de estimadores: 500
- Profundidad maxima de arboles: 5
- Learning rate: 0.02

- Metricas de desempeño del modelo:

- Recall: 82.6%
- F1-score: 0.229
- ROC-AUC: 0.886
- Presición: 78.0%



Muchas Gracias

