

El equipo estuvo conformado por Abraham Bohórquez, Samuel Arbeláez Ramírez y Lucas Muñoz. Desde el inicio del proyecto se mantuvo una organización clara del trabajo, dividiendo las responsabilidades de acuerdo con las preguntas de negocio planteadas y con los componentes técnicos necesarios para construir una solución completa de analítica predictiva sobre los resultados Saber 11 en el departamento de Córdoba.

De manera conjunta, el equipo asumió los roles de análisis de negocio y análisis de datos. En esta etapa se definió la audiencia objetivo del proyecto, enfocada principalmente en la Secretaría de Educación de Córdoba y en la toma de decisiones educativas basadas en evidencia. A partir de esto, se formularon tres preguntas de negocio orientadas a predecir el desempeño académico de los estudiantes en diferentes dimensiones: puntaje global, nivel de inglés A- y desempeño en matemáticas. También se trabajó de forma colaborativa en la exploración inicial de la base de datos, la selección de variables relevantes y la interpretación de los resultados obtenidos.

Abraham lideró el componente de predicción del puntaje global Saber 11. Su trabajo se enfocó en construir un modelo de regresión utilizando redes neuronales y selección de variables mediante LassoCV. Para esto realizó procesos de limpieza, codificación de variables, selección de predictores y comparación de modelos mediante métricas como RMSE, MAE, MAPE y R^2 . Además, identificó variables relevantes asociadas al desempeño académico, como características del colegio, jornada escolar, acceso a internet y nivel educativo de los padres.

Samuel lideró el componente de clasificación del nivel de inglés A-. Su trabajo consistió en construir un modelo predictivo para identificar estudiantes con alta probabilidad de ubicarse en el nivel más bajo de inglés. Para ello desarrolló modelos de clasificación binaria, principalmente redes neuronales tipo MLP, evaluando métricas como F1-score, ROC-AUC, PR-AUC y recall. Además, incorporó variables asociadas al colegio, municipio, conectividad del hogar y contexto familiar, permitiendo orientar el análisis hacia la identificación temprana de estudiantes en riesgo académico.

Lucas lideró el componente de matemáticas, cuyo objetivo fue predecir si un estudiante superaría el umbral de 70 puntos en la prueba de matemáticas Saber 11. Para esto realizó el preprocesamiento de los datos correspondientes, filtró los periodos comparables desde 2015 en adelante, construyó la variable objetivo y abordó el problema de desbalanceo de clases. Posteriormente entrenó y comparó modelos de redes neuronales y XGBoost, priorizando métricas como recall, F1-score y ROC-AUC, debido a la importancia de reducir falsos negativos. El modelo XGBoost fue seleccionado como el mejor clasificador final por su mayor recall y mejor desempeño general frente a la red neuronal.

El desarrollo del dashboard fue trabajado principalmente por Abraham y Lucas. En este componente se integraron los resultados de los tres modelos dentro de una aplicación interactiva construida en Dash y Plotly. El tablero fue diseñado con una estructura por pestañas, incluyendo una vista de panorama general, una sección de puntaje global, una sección de inglés y una sección de matemáticas. Además, se incorporaron visualizaciones dinámicas, métricas de desempeño, matrices de confusión y formularios de predicción. En todas las secciones se agregó un simulador interactivo que permite ingresar características del estudiante y obtener una predicción utilizando los modelos previamente entrenados.

Samuel asumió el rol principal de despliegue y mantenimiento. Su trabajo consistió en llevar el tablero a la nube mediante AWS, utilizando una instancia EC2 y una arquitectura basada en Docker. También configuró el entorno de ejecución, las dependencias necesarias, los archivos de despliegue y la exposición pública de la aplicación en el puerto correspondiente. Gracias a esto, el dashboard quedó disponible como una herramienta funcional y accesible para el usuario final, sin necesidad de reentrenar los modelos al momento de ejecutar la aplicación.

Durante el desarrollo del proyecto se utilizó GitHub como herramienta central de colaboración y control de versiones. Cada integrante trabajó sobre sus archivos y ramas correspondientes, realizando commits para documentar avances, integrar modelos, actualizar el dashboard y consolidar los archivos necesarios para la ejecución final. Además, se realizaron pruebas locales y revisiones cruzadas para verificar que los modelos, el tablero y el despliegue funcionaran correctamente.

En conjunto, el equipo logró integrar limpieza de datos, análisis exploratorio, modelamiento predictivo, visualización interactiva y despliegue en la nube. El resultado final fue una solución completa orientada a apoyar

decisiones educativas en Córdoba, permitiendo analizar patrones históricos de desempeño y generar predicciones individuales que pueden servir como insumo para estrategias de refuerzo académico y acompañamiento estudiantil.